

Pour le réseau neuronnal de la figure 5.1, on a établi que pour une sortie y_k :

$$y_k = f(a_k) = f\left(\sum_{j=0}^M w_{kj}^{(2)} \sigma\left(\sum_{i=0}^D w_{ji}^{(1)} x_i\right)\right)$$

RÉGRESSION

Dans le cas d'une régression, il n'y a qu'une seule sortie :

$$y(\vec{x}, \vec{w}) = f(a)$$

Le modèle choisi :

$$p(t|\vec{x}, \vec{w}) = \mathcal{N}(t|y(\vec{x}, \vec{w}), \beta^{-1})$$

Puisque a peut approximer n'importe quelle fonction pour tout t , il n'est pas nécessaire de transformer a . On choisit :

$$y(\vec{x}, \vec{w}) = f(a) = a$$

$$p(\vec{\mathbf{t}}|\mathbf{X}, \vec{w}, \beta) = \prod_{n=1}^N p(t_n|\vec{x}_n, \vec{w}, \beta)$$

$$E(\vec{w}) = \frac{1}{2} \sum_{n=1}^N \{y(\vec{x}_n, \vec{w}) - t_n\}^2$$

DEUX CLASSES

Dans le cas d'une classification binaire, il n'y a qu'une seule sortie :

$$y(\vec{x}, \vec{w}) = f(a)$$

Le modèle choisi :

$$p(t|\vec{x}, \vec{w}) = y(\vec{x}, \vec{w})^t \{1 - y(\vec{x}, \vec{w})\}^{1-t}$$

Dans le modèle choisi, t suit une loi de Bernouilli de paramètre $y(\vec{x}, \vec{w})$. Cette loi est membre de la famille exponentielle. Lorsque la loi de Bernouilli est exprimée sous la forme générale de la famille exponentielle, la paramètre naturel η de la distribution est lié à l'espérance μ par la fonction ψ :

$$\eta = \psi(\mu) = \ln\left(\frac{\mu}{1-\mu}\right)$$

ψ est appelée la *fonction de liaison canonique*. Elle a un inverse :

$$\mu = \psi^{-1}(\eta) = \sigma(\eta) = \frac{1}{1+\exp(-\eta)}$$

On choisit $f(a) = \psi^{-1}(a)$. En plus d'établir une correspondance entre les composantes du modèle et les paramètres de la distribution exponentielle, ce choix permet de tirer quelques généralisations additionnelles (voir section 4.3.6). On a donc :

$$y(\vec{x}, \vec{w}) = f(a) = \sigma(a) = \frac{1}{1+\exp(-a)}$$

$$p(\vec{\mathbf{t}}|\mathbf{X}, \vec{w}) = \prod_{n=1}^N y(\vec{x}_n, \vec{w})^{t_n} \{1 - y(\vec{x}_n, \vec{w})\}^{(1-t_n)}$$

$$E(\vec{w}) = - \sum_{n=1}^N t_n \ln \{y(\vec{x}_n, \vec{w})\} + (1 - t_n) \ln \{1 - y(\vec{x}_n, \vec{w})\}$$

PLUSIEURS CLASSES

Dans le cas d'une classification multi-classes, il y K sorties :

$$y_k(\vec{x}, \vec{w}) = f(a_k)$$

Le modèle choisi :

$$p(\vec{t}|\vec{x}, \vec{w}) = \prod_{k=1}^K \{y_k(\vec{x}, \vec{w})\}^{t_k}$$

Dans le modèle choisi, \vec{t} suit une loi multinomiale de paramètres K et $\vec{y}(\vec{x}, \vec{w})$. Cette loi est membre de la famille exponentielle. Lorsque la loi multinomiale est exprimée sous la forme générale de la famille exponentielle, la paramètre naturel $\vec{\eta}$ de la distribution est lié à l'espérance $\vec{\mu}$ par la fonction ψ :

$$\eta_k = \psi(\mu_k) = \ln\left(\frac{\mu_k}{1-\sum_j \mu_j}\right)$$

$$\mu_k = \psi^{-1}(\eta_k) = \frac{\exp(\eta_k)}{\sum_j \exp(\eta_j)}$$

On choisit $f(a_k) = \psi^{-1}(a_k)$:

$$y_k(\vec{x}, \vec{w}) = f(a_k) = \frac{\exp(a_k)}{\sum_j \exp(a_j)}$$

$$p(\mathbf{T}|\mathbf{X}, \vec{w}) = \prod_{n=1}^N \prod_{k=1}^K y_k(\vec{x}_n, \vec{w})^{t_{nk}}$$

où t_{nk} et la k^e composante de la cible \vec{t} de la n^e observation.

$$E(\vec{w}) = - \sum_{n=1}^N \sum_{k=1}^K t_{nk} \ln \{y_k(\vec{x}_n, \vec{w})\}$$